Техническое задание: Построить систему автоматической генерации 3D-жестов РЖЯ из видео на базе MediaPipe

Контекст:

Я создаю образовательную платформу VisualMind для людей с нарушением слуха.

Мне необходимо построить полный production-ready pipeline, который автоматически преобразует видео человека, показывающего жесты русского жестового языка (РЖЯ), в анимации 3D-аватара.

Главная цель:

Не хранить тысячи видео жестов.

Вместо этого хранить движения в виде структурированных данных (координаты, скелет, анимации), которые затем можно воспроизводить на любом 3D-аватаре.

Что должна уметь система

Вход:

- mp4 видео человека
- одно слово или одна фраза РЖЯ
- видео снято на обычный телефон
- фронтально

Выход:

- gesture.json
- glb/fbx анимация
- воспроизведение на 3D-аватаре

Архитектура

Этап 1. Захват движений

Использовать:

MediaPipe Holistic

Извлекать:

- pose landmarks
- left hand landmarks
- right hand landmarks
- face landmarks

Для каждого кадра сохранять:

timestamp pose left_hand right_hand face

Пример структуры:

{ "frame": 120, "timestamp": 4.00, "pose": [...], "left_hand": [...], "right_hand": [...], "face": [...] }

Этап 2. Нормализация

Необходимо решить проблему разных людей.

Нормализовать:

- рост
- длину рук
- расстояние до камеры
- масштаб

Привести все жесты к единой системе координат.

Опорная точка:

центр плеч.

Этап 3. Очистка данных

Убрать шумы.

Использовать:

- moving average
- Kalman Filter
- Savitzky-Golay Filter

Сравнить качество каждого подхода.

Этап 4. Анализ пальцев

Это критически важно.

Для РЖЯ различия между словами часто зависят только от:

- положения пальцев
- направления ладони
- сгиба фаланг

Необходимо вычислять:

- углы суставов
- сгиб каждого пальца
- раскрытие ладони
- ориентацию кисти

Сохранять эти параметры отдельно.

Этап 5. Формирование gesture.json

Предложить оптимальную структуру.

Пример:

{ "word": "привет", "duration": 2.4, "frames": [], "metadata": {} }

Структура должна быть масштабируемой для десятков тысяч жестов.

Этап 6. Ретаргетинг на аватар

Использовать:

- Blender
- Mixamo
- ReadyPlayerMe
- VRM

Необходимо автоматически переносить движения MediaPipe на кости аватара.

Рассмотреть:

Inverse Kinematics (IK)

Forward Kinematics (FK)

Этап 7. Экспорт

Генерировать:

- glb

- fbx
- vrm animation

Этап 8. Веб-плеер

Frontend:

React + Three.js + React Three Fiber

Возможности:

- загрузка gesture.json
- воспроизведение аватара
- регулировка скорости
- пауза
- перемотка

Особенности РЖЯ

Обязательно учитывать:

1. Движение рук
2. Положение пальцев
3. Направление ладони
4. Положение головы
5. Мимику
6. Направление взгляда

Не игнорировать лицо.

Для некоторых жестов лицо меняет смысл.

Масштабирование

Система должна позволять:

10000+ жестов

без хранения видео.

Нужно хранить только:

- координаты
- параметры суставов
- анимации

Оптимизация хранения

Предложить:

- сжатие ключевых кадров
- интерполяцию
- удаление дубликатов кадров

Цель:

уменьшить размер gesture.json в 10-50 раз.

AI уровень

Предложить архитектуру, которая в будущем позволит:

Видео → MediaPipe → Gesture JSON → Embedding → Поиск похожих жестов → Распознавание РЖЯ → Генерация новых жестов

Ожидаемый результат

Подготовь:

1. Полную архитектуру.
2. Схему БД.
3. Формат gesture.json.
4. Backend API.
5. Frontend архитектуру.
6. Blender pipeline.
7. Retargeting pipeline.
8. Оптимизацию хранения.
9. Docker deployment.
10. План разработки MVP за 30 дней.

Сделай решение уровня production и рассчитанное на дальнейший рост до полноценного словаря русского жестового языка.